

معسكر هندسة الذكاء الاصطناعي (AIEP) المؤهل للتوظيف

اليوم الخامس



موضوعات الجلسة

1 التعلم غير الخاضع للإشراف

2 التجميع باستخدام خوارزمية K-Means

3 تقليل الأبعاد باستخدام تحليل المكونات الرئيسية (PCA)

4 التضمين العشوائي للجيران باستخدام t-SNE

إرشادات الجلسات



أنتم المدرب الأهم

إجاباتكم قد تكون أحياناً أهم من محتوانا لزملائكم، لذلك لا تترددون في الإجابة على بعض، وبرضو ما يمنع تعبّرونا وتجاوبوا على أسئلتنا



ما فيه سؤال غلط

ما يهمّ وش تخصصكم أو مدى خبرتكم، كلنا جينا نتعلم هنا من بعض، لذلك لا تترددون في السؤال، لأنه ما فيه سؤال غلط



o تفاعل = o فائدة

التفاعل أساس الجلسة، خلوكم جاهزين تجاوبون على أسئلة وتشتغلون مع بعض في الجلسة

سَجِّينَا بِاللَّهِ ؟

التعلّم غير الخاضع للإشراف

اليوم الخامس

معسكر هندسة الذكاء الاصطناعي (AIEP)



دقيقة واحدة

نشاط 1

هل تستطيع اكتشاف النمط؟

2, 4, 8, 10, 20, 22, 44, ?





دقيقة واحدة

نشاط 1

الإجابة:

2, 4, 8, 10, 20, 22, 44, 46

النمط:

+2, ×2, +2, ×2, +2, ×2..




دقيقتان

نشاط ٢

هل تستطيع تقسيم هؤلاء العملاء إلى مجموعات؟

العميل	عدد الزيارات	متوسط مدة الجلسة	عدد المشتريات
A	2	5	0
B	3	7	1
C	8	25	5
D	9	28	6
E	7	22	4
F	2	6	0
G	10	30	7
H	3	8	1
I	8	26	5
J	2	5	0






دقيقة واحدة


نشاط 2

الاجابة:

بعد التقسيم




ما الذي يخبرنا به هذا الرسم البياني؟




معرف المبنى	استهلاك الكهرباء (kWh/day)	استهلاك المياه (L/day)	حجم النفايات الناتجة (kg/day)	نسبة تغطية الطاقة الشمسية (%)	عمر المبنى Age (years)
1	320	900	14	10	8
2	180	600	8	40	3
3	450	1200	20	5	15
4	200	700	9	35	5
5	150	500	6	60	2
6	380	1000	15	20	12
7	520	1300	22	0	18
8	240	650	10	30	4
9	130	480	5	70	1
10	410	1100	17	15	10

المباني التي تظهر متقاربة لها أنماط استهلاك موارد متشابهة




معرف المبنى	استهلاك الكهرباء (kWh/day)	استهلاك المياه (L/day)	حجم النفايات الناتجة (kg/day)	نسبة تغطية الطاقة الشمسية (%)	عمر المبنى Age (years)
1	320	900	14	10	8
2	180	600	8	40	3
3	450	1200	20	5	15
4	200	700	9	35	5
5	150	500	6	60	2
6	380	1000	15	20	12
7	520	1300	22	0	18
8	240	650	10	30	4
9	130	480	5	70	1
10	410	1100	17	15	10

المباني التي تظهر متقاربة لها أنماط استهلاك موارد متشابهة




معرف المبنى	استهلاك الكهرباء (kWh/day)	استهلاك المياه (L/day)	حجم النفايات الناتجة (kg/day)	نسبة تغطية الطاقة الشمسية (%)	عمر المبنى Age (years)
1	320	900	14	10	8
2	180	600	8	40	3
3	450	1200	20	5	15
4	200	700	9	35	5
5	150	500	6	60	2
6	380	1000	15	20	12
7	520	1300	22	0	18
8	240	650	10	30	4
9	130	480	5	70	1
10	410	1100	17	15	10

المباني التي تظهر متقاربة لها أنماط استهلاك موارد متشابهة



معرف المبنى	استهلاك الكهرباء (kWh/day)	استهلاك المياه (L/day)	حجم النفايات الناتجة (kg/day)	نسبة تغطية الطاقة الشمسية (%)	عمر المبنى Age (years)
1	320	900	14	10	8
2	180	600	8	40	3
3	450	1200	20	5	15
4	200	700	9	35	5
5	150	500	6	60	2
6	380	1000	15	20	12
7	520	1300	22	0	18
8	240	650	10	30	4
9	130	480	5	70	1
10	410	1100	17	15	10


المباني التي تظهر متقاربة لها أنماط استهلاك موارد متشابهة



معرف المبنى	استهلاك الكهرباء (kWh/day)	استهلاك المياه (L/day)	حجم النفايات الناتجة (kg/day)	نسبة تغطية الطاقة الشمسية (%)	عمر المبنى Age (years)
1	320	900	14	10	8
2	180	600	8	40	3
3	450	1200	20	5	15
4	200	700	9	35	5
5	150	500	6	60	2
6	380	1000	15	20	12
7	520	1300	22	0	18
8	240	650	10	30	4
9	130	480	5	70	1
10	410	1100	17	15	10

التعلّم غير الخاضع للإشراف - Unsupervised Learning

التعلّم غير الخاضع للإشراف هو نوع من التعلم الآلي يتعلم فيه النموذج الأنماط أو البنية الموجودة في البيانات دون الاعتماد على Labels محددة مسبقاً.



تحليل الشبكات الاجتماعية




تجزئة السوق

التجميع باستخدام خوارزمية K-Means

التجميع باستخدام خوارزمية K-Means

خوارزمية K-Means هي خوارزمية تعلّم غير خاضع للإشراف تُستخدم لتقسيم البيانات إلى K مجموعات (Clusters)، بحيث تكون النقاط داخل المجموعة الواحدة متشابهة قدر الإمكان.



مفهوم المركز (Centroid)

كل مجموعة لها مركز (Centroid) يمثل متوسط جميع النقاط الموجودة فيها.

ببساطة: المركز هو النقطة التي تمثل متوسط المجموعة.

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

نقطة بيانات $\rightarrow$ x_i

مركز المجموعة k $\rightarrow$ μ_k

عدد النقاط في المجموعة $\rightarrow$ $|C_k|$

النقاط الموجودة في المجموعة k $\rightarrow$ $x_i \in C_k$

حساب المسافة

تستخدم K-Means عادةً المسافة الإقليدية (Euclidean Distance) لقياس قرب نقطة البيانات من كل مركز.

كلما كانت المسافة أصغر، كانت النقطة أقرب إلى المركز.

$$d(x_i, \mu_k) = \sqrt{\sum_{j=1}^n (x_{ij} - \mu_{kj})^2}$$

المسافة بين النقطة والمركز ← $d(x_i, \mu_k)$

نقطة بيانات ← x_i

مركز المجموعة k ← μ_k

قيمة المتغير j في النقطة x_i ← x_{ij}

قيمة المتغير j في المركز μ_k ← μ_{kj}

دالة الهدف Inertia / (Objective Function)

تهدف K-Means إلى تقليل مجموع مربعات المسافات بين كل نقطة والمركز الخاص بالمجموعة التي تنتمي إليها.

الهدف: جعل قيمة Inertia صغيرة قدر الإمكان، أي أن تكون النقاط قريبة من مراكز مجموعاتها.

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

عدد المجموعات ← K

← قيمة دالة الهدف (Inertia)

← x_i نقطة بيانات

← μ_k مركز المجموعة k

← C_k المجموعة k

التكرار: التعيين ثم التحديث

تعمل الخوارزمية بشكل تكراري من خلال خطوتين رئيسيتين:

1- التعيين (Assignment) تُسند كل نقطة إلى أقرب مركز.

$$C_k = \{x_i : d(x_i, \mu_k) \min \}$$

2- التحديث (Update) بعد إعادة توزيع النقاط، يتم حساب مركز جديد لكل مجموعة.

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

3- ثم تتكرر الخطوتان:
 تحديث المراكز → تعيين النقاط → تحديث المراكز → تعيين النقاط

التقارب (Convergence)

تستمر الخوارزمية في تكرار خطوات التعيين والتحديث حتى تصل إلى حالة استقرار.

يحدث التقارب عندما:

- لا تتغير المجموعات، أو
- لا تتغير المراكز بشكل ملحوظ، أو
- يصبح التحسن في دالة الهدف صغيرًا جدًا.

عندها تتوقف الخوارزمية.

المعامل K


يمثل K عدد المجموعات التي نريد تقسيم البيانات إليها.

مثلاً:

$K=3$ يعني أننا نريد تقسيم البيانات إلى 3 مجموعات.


ملاحظة مهمة: قيمة K لا تتعلمها الخوارزمية تلقائياً، بل يجب تحديدها قبل تشغيل K-Means.

مثال:




مثال:

التهيئة العشوائية للمجموعات (Random Initialization of Clusters)




مثال:

خطوة إسناد النقاط إلى المجموعات (Cluster Assignment Step)





مثال:

خطوة تحريك المراكز (Move Centroid Step)




مثال:

خطوة إسناد النقاط إلى المجموعات (Cluster Assignment Step)





مثال:

خطوة تحريك المراكز (Move Centroid Step)





مثال:

خطوة إسناد النقاط إلى المجموعات (Cluster Assignment Step)



مثال:


نتوقف عندما لا يوجد تحسين اضافي



العثور على global optima هي مشكلة NP-Hard

الحل:


تشغيل خوارزمية K-Means عدة مرات واختيار التجميع الذي يحقق أقل تكلفة



كم عدد المجموعات K التي يجب أن نستخدمها؟

الحل استخدام طريقة (elbow):

- تشغيل خوارزمية K-Means عدة مرات.
- كل مرة برقم K مختلف.
- واختيار K الذي يحقق شكل المرفق (elbow).




متى تفشل خوارزمية K-Means

تفترض K-Means أن المجموعات:


- ذات شكل كروي.
- متقاربة في الحجم.

المشكلة 1: المجموعات غير الكروية Non-spherical Clusters

- قد تفشل K-Means مع المجموعات التي لها أشكال معقدة، مثل الدوائر المتداخلة.



Fails on concentric circles!




Struggles with size differences!

- تفشل مع الدوائر متحدة المركز.

المشكلة 2: اختلاف أحجام المجموعات Different Cluster Sizes

- تواجه K-Means صعوبة عندما تكون أحجام المجموعات مختلفة بشكل كبير.
- صعوبة في التعامل مع اختلاف أحجام المجموعات.

التجميع باستخدام K-Means خوارزمية



استراحة

10 دقائق

أهلاً بعودتكم

تقليل الأبعاد باستخدام تحليل المكوّنات الرئيسية (PCA)

ما هو PCA (Principal Component Analysis)؟

تحليل المكونات الرئيسية (PCA) هو خوارزمية لتقليل أبعاد البيانات، تبحث عن أهم الاتجاهات في البيانات.

الفكرة الأساسية:

بدلاً من استخدام المتغيرات الأصلية، ننشئ متغيرات جديدة تسمى المكونات الرئيسية (Principal Components)، بحيث:

- تلتقط أكبر قدر ممكن من التباين في البيانات
 - تكون غير مترابطة مع بعضها
 - يتم ترتيبها حسب مقدار المعلومات التي تحتفظ بها
- ثم نحتفظ فقط بأهم المكونات!



الحدس وراء PCA: البحث عن أفضل الاتجاهات

الهدف:

البحث عن الاتجاهات التي تتغير فيها البيانات بأكثر قدر ممكن.

PC1 أكبر تباين

PC2 ثاني أكبر تباين

... PC3، PC4

الاتجاهات التالية


• PC1: الاتجاه الذي تنتشر فيه البيانات بأكثر قدر

• PC2: اتجاه عمودي على PC1 ويحتوي على ثاني أكبر تباين

• PC3، PC4، ...: كل مكّون يكون عمودياً على المكّونات السابقة

ببساطة:

40 يحاول أن يجد أفضل اتجاهات يمكن من خلالها تمثيل البيانات بأقل عدد ممكن من الأبعاد



كيف يعمل PCA؟ (الجزء الأول)

الخطوة 1: تجهيز البيانات

1- توسيط البيانات (Centering)

نحرّك البيانات بحيث يصبح مركزها عند نقطة الأصل (0, 0).
أي: نطرح متوسط كل متغير من قيمه.

$$X_{\text{centered}} = X - \bar{X}$$

كيف يعمل PCA؟ (الجزء الأول)

2- حساب مصفوفة التباين المشترك (Covariance Matrix)
نحسب كيف تتغير المتغيرات بالنسبة لبعضها.

الفكرة:

مصفوفة التباين المشترك تساعدنا على معرفة العلاقة بين المتغيرات وكيف تتحرك معًا.

$$C = \frac{1}{n} X_{\text{centered}}^{\top} X_{\text{centered}}$$

كيف يعمل PCA؟ (الجزء الثاني)

الخطوة 2: إيجاد الاتجاهات والإسقاط:

3. إيجاد المكونات الرئيسية

نحسب المتجهات الذاتية (Eigenvectors) والقيم الذاتية (Eigenvalues) لمصفوفة التباين المشترك C.

- Eigenvectors: تحدد اتجاهات المحاور الجديدة.
- Eigenvalues: توضح مقدار التباين أو المعلومات الموجودة في كل اتجاه.

ببساطة:

المتجه الذاتي → الاتجاه

القيمة الذاتية → كمية المعلومات في هذا الاتجاه

كيف يعمل PCA؟ (الجزء الثاني)

4. اختيار المكوّنات وإسقاط البيانات
نختار أول k متجهات ذاتية التي تمتلك أكبر قيم ذاتية، ثم نستخدمها لتحويل البيانات.

$$Z = X_{\text{centered}} \cdot V_k$$

حيث يتم تقليل البيانات من:

$$d \rightarrow k$$

مثال:

784 أبعاد $\rightarrow$ 50 مكوّنًا

كم مكوّنًا نحتفظ به؟

كم عدد المكوّنات الذي نحتاجه؟

نستخدم غالبًا التباين التراكمي المفسّر (Cumulative Variance Explained). وهو يوضح كم نسبة المعلومات الأصلية التي ما زلنا نحتفظ بها. قاعدة تقريبية:


اختر أصغر قيمة لـ K تحافظ على حوالي: 80% – 95% من التباين الكلي. مثلاً:

10 مكوّنات → 82%

20 مكوّنًا → 91%

30 مكوّنًا → 95%

(The most common method for selecting K)



كلما زاد عدد المكوّنات، احتفظنا بمعلومات أكثر، لكن قلّ مقدار تقليل الأبعاد.

ما هي استخدامات تقليل الأبعاد؟

1- تصوّر البيانات (Data Visualization)

تقليل عدد الأبعاد يجعل من السهل عرض البيانات وفهمها بصريًا.

2- تحسين دقة النموذج

تقليل البيانات المضللة أو غير المهمة قد يساعد النموذج على تحسين دقته.

3- تسريع عملية التعلّم (Speed Up Learning)

عدد أبعاد أقل يعني عمليات حسابية أقل، وبالتالي يمكن للخوارزميات تدريب النماذج بشكل أسرع.

4- ضغط البيانات (Data Compression)


تقليل عدد الأبعاد يعني بيانات أقل، وبالتالي مساحة تخزين أقل مطلوبة.

التطبيق 1: تصور البيانات

البيانات: MNIST

مجموعة بيانات تحتوي على 70,000 صورة لأرقام مكتوبة باليد من 0 إلى 9.
التحدي:


- حجم كل صورة: 28×28 بكسل
- عدد المتغيرات: 784




أي أن كل صورة لديها 784 بُعدًا!
لكن لا يمكننا تصور البيانات في 784 بُعدًا.
السؤال:

هل يمكننا تقليلها إلى بُعدين فقط لرؤية العلاقة بين الأرقام؟

التطبيق 1: تصور البيانات



هل هذا أفضل تصور للبيانات؟



هل هذا أفضل لتصور للبيانات؟

ليس دائمًا.

- PCA يستطيع إظهار بعض البنية الموجودة في البيانات.
- لكن قد تتداخل النقاط مع بعضها بشكل كبير.
- السبب: PCA خوارزمية خطية، لذلك قد لا تستطيع تمثيل العلاقات المعقدة والمنحنية.

إذن:

PCA مفيد جدًا في تقليل الأبعاد وضغط البيانات، لكن قد لا يكون الأفضل دائمًا لتصور البيانات المعقدة.

سنتعرف بعد قليل على خوارزمية أفضل لتصور البيانات عالية الأبعاد.


التطبيق 2: ضغط البيانات

الاستخدام:

تخزين البيانات بطريقة أكثر كفاءة.

البيانات الأصلية 784

$$28 \times 28 = 784$$



البيانات المضغوطة 50 مكوّنًا

مثال:

[0.42, -1.3, 0.87, ...]

إعادة البناء (Reconstruction)

البيانات المعاد بناؤها

تشبه البيانات الأصلية، ولكن مع خطأ بسيط.

العلاقة بين عدد المكوّنات وجودة البيانات

200 مكوّن

ضغط أقل - الصورة قريبة
جداً من الأصل

50 مكوّن

ضغط جيد - جودة جيدة

10 مكوّنات

ضغط أكبر - جودة أقل -
الصورة قد تكون ضبابية

القاعدة:

مكوّنات أكثر → جودة أفضل + ضغط أقل
مكوّنات أقل → ضغط أكبر + فقدان معلومات أكثر

قيود PCA

أهم القيود:

- خطي فقط: يبحث عن اتجاهات خطية في البيانات.
- حساس لمقياس البيانات: من الأفضل توحيد البيانات قبل تطبيق PCA عندما تكون المتغيرات بمقاييس مختلفة.
- صعوبة التفسير: المكوّنات الجديدة عبارة عن تركيبات من المتغيرات الأصلية.
- يتأثر بالقيم الشاذة (Outliers): القيم الشاذة يمكن أن تغيّر الاتجاهات التي يكتشفها PCA.

 خمس دقائق

نشاط 3

تحدي المصنع الذكي:

أنت مهندس ذكاء اصطناعي في مصنع ذكي ينتج رقائق إلكترونية دقيقة. خط الإنتاج يولد آلاف الصور اليومية لمكونات تمر عبر الحزام الناقل، ولكن جميع الصور ضبابية ومظلمة جزئياً، والأهم من ذلك: لا توجد أي بيانات تصنيفية مسبقة (No Labels)، يعني لا توجد صور مصنفة مسبقاً كـ 'سليمة' أو 'معيبة'.



- ما هي المشكلة الحقيقية التي تواجه مهندس الذكاء الاصطناعي هنا؟
- ما هو المطلوب إنجازه تقنياً للتعامل مع هذا الوضع؟
- كيف ستقوم بالحل؟



خمس دقائق

نشاط 3

كشف الشذوذ (Anomaly Detection)

الخطوة 3: كشف الشذوذ (Outliers)

النقاط البعيدة كلياً عن مراكز التجمعات (Centroids) تُعتبر تلقائياً تالفة ومعيبة!

الخطوة 2: التجميع الأكبر (K-Means)

تجميع الصور المتشابهة في مجموعة رئيسية ضخمة تمثل المنتجات السليمة.

الخطوة 1: تقليل الأبعاد (PCA)

استخلاص أهم الخصائص البصرية وضغط بكسلات الصور لتقليل التشويش الضبابي.

التضمين العشوائي للجيران باستخدام t-SNE

لماذا نحتاج إلى t-SNE؟

PCA مفيد جدًا، لكنه خطي.
والعديد من مجموعات البيانات تحتوي على بنية غير خطية.
المشكلة:

- البيانات عالية الأبعاد يصعب تصورها.
- PCA قد يخلط بين المجموعات عندما يكون الفصل بينها غير خطي.
- في كثير من الحالات نريد فقط الحصول على رسم ثنائي الأبعاد واضح لاستكشاف البيانات.


لذلك:
نحتاج إلى خوارزمية أخرى للتصور...

التضمين العشوائي للجيران الموزع وفق t

t-Distributed Stochastic Neighbor Embedding (t-SNE)

الفكرة الأساسية:

يحاول t-SNE إنشاء خريطة ثنائية الأبعاد تحافظ على الجيران القريبين من بعضهم.




الفكرة:

النقاط المتقاربة في الأبعاد العالية تبقى متقاربة قدر الإمكان في الخريطة ثنائية الأبعاد.

مثال: تصور MNIST باستخدام t-SNE

- باستخدام t-SNE يمكننا رؤية مجموعات الأرقام المتشابهة بشكل أوضح.
- الأرقام المتشابهة تميل إلى التجمع معًا.
 - الأرقام المختلفة تميل إلى الظهور في مناطق مختلفة.
- لذلك يمكن أن يكون t-SNE مناسبًا جدًا لاستكشاف وتصوّر البيانات عالية الأبعاد.



قبل ما نمشي

ايش أهم قرار هندسي بتأخذه
بشكل مختلف بعد اليوم؟