

معسكر هندسة الذكاء الاصطناعي (AIEP) المؤهل للتوظيف

الأسبوع ٣ - اليوم الثاني

إرشادات الجلسات



أنتم المدرب الأهم

إجاباتكم قد تكون أحياناً أهم من
محتوانا لزملائكم، لذلك لا
ترددون في الإجابة على بعض،
وبرضو ما يمنع تعبّرونا وتجاوبوا
على أسئلتنا



ما فيه سؤال غلط

ما يهمّ وش تخصصكم أو مدى
خبرتكم، كلنا جينا نتعلم هنا من
بعض، لذلك لا ترددّون في
السؤال، لأنه ما فيه سؤال غلط



o تفاعل = o فائدة

التفاعل أساس الجلسة، خلوكم
جاهزين تجاوبون على أسئلة
وتشتغلون مع بعض في الجلسة

سَجِّينَا بِاللَّهِ ؟

التعلم العميق

الأسبوع ٣ - اليوم الثاني
معسكر هندسة الذكاء الاصطناعي (AIEP)

موضوعات الجلسة

1 الانتشار العكسي


2 تهيئة الوزن

3 تدريب الشبكات العصبية



دقيقة واحدة

نشاط 1



كم عدد المعاملات المتعلمة ؟





دقيقة واحدة

نشاط 1

كم عدد المعاملات المتعلمة ؟

39


الطبقة	Weights	Biases	المجموع
Input (3) → Hidden 1 (4)	$3 \times 4 = 12$	4	16
Hidden 1 (4) → Hidden 2 (2)	$4 \times 2 = 8$	2	10
Hidden 2 (2) → Hidden 3 (3)	$2 \times 3 = 6$	3	9
Hidden 3 (3) → Output (1)	$3 \times 1 = 3$	1	4



الانتشار العكسي

الانتشار العكسي – Backpropagation

• Backpropagation هي الطريقة التي تتعلم بها الشبكة العصبية من أخطائها



الانتشار العكسي – Backpropagation

- يتم أولاً حساب الخطأ (Error) عند طبقة الإخراج Output Layer.
- ثم يتم نشر هذا الخطأ عكسيًا عبر الشبكة لتحديث الأوزان (Weights) والانحيازات (Biases) في كل طبقة.

$$dz^{[2]} = a^{[2]} - y$$

$$dW^{[2]} = dz^{[2]} a^{[1]T}$$

$$db^{[2]} = dz^{[2]}$$

$$dz^{[1]} = W^{[2]T} dz^{[2]} \odot g^{[1]'}(z^{[1]})$$

$$dW^{[1]} = dz^{[1]} x^T$$

$$db^{[1]} = dz^{[1]}$$

الانتشار العكسي – Backpropagation

- النسخة المتجهة (Vectorized) من الـ Backpropagation تسمح بحساب الـ Gradients بكفاءة لجميع أمثلة التدريب دفعة واحدة.
- ثم يتم أخذ متوسط الـ Gradients عبر الـ Batch لتحديث الأوزان والانحيازات.

$$dZ^{[2]} = A^{[2]} - Y$$


$$dW^{[2]} = \frac{1}{m} dZ^{[2]} A^{[1]T}$$

$$db^{[2]} = \frac{1}{m} \sum_{i=1}^m dZ_{:,i}^{[2]}$$

$$dZ^{[1]} = W^{[2]T} dZ^{[2]} \odot g^{[1]'}(Z^{[1]})$$

$$dW^{[1]} = \frac{1}{m} dZ^{[1]} X^T$$


$$db^{[1]} = \frac{1}{m} \sum_{i=1}^m dZ_{:,i}^{[1]}$$



تهيئة الأوزان

تهيئة الأوزان – Weights Initialization

هي طريقة تحديد القيم الابتدائية للأوزان قبل بدء تدريب الشبكة العصبية.




$$W^{[1]} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$$

$$b^{[1]} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

- إذا بدأنا جميع الأوزان بالقيمة صفر:
- فإن جميع ال-Neurons في الطبقة ستتعلم الشيء نفسه وتحصل على نفس التحديثات.
- لذلك في الشبكات العصبية لا نهى جميع الأوزان بالصفر، بل نستخدم عادةً قيمًا عشوائية مناسبة.
- يمكن تهيئة Biases بالصفر، لكن ليس كل Weights.

تهيئة الأوزان — Weights Initialization

تهيئة الأوزان عشوائيًا — Initialize Weights Randomly



$$W^{[1]} = \begin{pmatrix} \epsilon_1 & \epsilon_2 \\ \epsilon_3 & \epsilon_4 \end{pmatrix}$$

$$W^{[2]} = (\epsilon_5 \quad \epsilon_6)$$

$$b^{[1]} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$b^{[2]} = 0$$

ϵ are small random numbers

تهيئة الأوزان — Weights Initialization

تهيئة الأوزان عشوائيًا — Initialize Weights Randomly

- هذا يساعد على كسر التماثل (Symmetry) بين ال-Neurons.

- بالتالي تستطيع كل خلية عصبية تعلم خصائص مختلفة.

$$W^{[1]} \sim \mathcal{N}(0, \epsilon), \quad b^{[1]} = 0$$

$$z^{[1]} = W^{[1]}x + b^{[1]} \neq 0$$

$$a^{[1]} = g(z^{[1]}) \quad (\text{different for each neuron})$$

تهيئة الأوزان — Weights Initialization

Backpropagation effect

$$dz^{[1]} = W^{[2]T} dz^{[2]} \odot g'(z^{[1]})$$

$$dW^{[1]} = dz^{[1]} x^T$$

$$dW_1^{[1]} \neq dW_2^{[1]} \neq \dots$$

$$W_1^{[1]} \neq W_2^{[1]} \neq \dots \quad \forall \text{ iterations}$$


Random initialization $\Rightarrow$ symmetry breaking

تهيئة الأوزان عشوائيًا — Initialize Weights Randomly

- هذا يساعد على كسر التماثل (Symmetry) بين ال-Neurons.
- بالتالي تستطيع كل خلية عصبية تعلم خصائص مختلفة.


التحسين

خوارزميات التحسين – Optimizers




- هي خوارزميات تقوم بتحديث معاملات النموذج مثل Weights و Biases بهدف تقليل Loss Function أثناء التدريب.
- تُعد ال Optimizers جزءًا أساسيًا من نماذج Deep Learning.
- كل Optimizer يستخدم طريقة مختلفة لتحديث الأوزان.
- لذلك قد تختلف سرعة التقارب (Convergence) وأداء النموذج حسب ال Optimizer المستخدم.

Gradient Descent 1 – الانحدار المتدرج



- Gradient Descent هي خوارزمية تحسين تقوم بتحديث الأوزان في الاتجاه الذي يؤدي إلى أكبر انخفاض في قيمة الـ Loss.

2 الانحدار المتدرج باستخدام دفعات صغيرة – Mini-Batch Gradient Descent



Common mini-batch sizes are 32/64/128 examples

2 الانحدار المتدرج باستخدام دفعات صغيرة – Mini-Batch Gradient Descent

- بدلاً من استخدام جميع بيانات التدريب أو استخدام مثال واحد فقط في كل تحديث، نقسم البيانات إلى دفعات صغيرة (Mini-Batches).

• الخلط (Shuffle)


• التقسيم (Partition)

$$X = \begin{pmatrix} x_0^{(1)} & x_0^{(2)} & \dots & x_0^{(m-1)} & x_0^{(m)} \\ x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(m-1)} & x_1^{(m)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{12286}^{(1)} & x_{12286}^{(2)} & \dots & x_{12286}^{(m-1)} & x_{12286}^{(m)} \\ x_{12287}^{(1)} & x_{12287}^{(2)} & \dots & x_{12287}^{(m-1)} & x_{12287}^{(m)} \end{pmatrix}$$

$$Y = \begin{pmatrix} y^{(1)} & y^{(2)} & \dots & y^{(m-1)} & y^{(m)} \end{pmatrix}$$

$$Y = \begin{pmatrix} y^{(1)} & y^{(2)} & \dots & y^{(m-1)} & y^{(m)} \end{pmatrix}$$


$$X = \begin{pmatrix} x_0^{(1)} & x_0^{(2)} & \dots & x_0^{(m-1)} & x_0^{(m)} \\ x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(m-1)} & x_1^{(m)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{12286}^{(1)} & x_{12286}^{(2)} & \dots & x_{12286}^{(m-1)} & x_{12286}^{(m)} \\ x_{12287}^{(1)} & x_{12287}^{(2)} & \dots & x_{12287}^{(m-1)} & x_{12287}^{(m)} \end{pmatrix}$$




3 الانحدار التدريجي العشوائي SGD = Stochastic Gradient Descent

هو خوارزمية تحسين تقوم بتحديث أوزان النموذج باستخدام عينة واحدة فقط في كل خطوة لتقليل قيمة دالة الخسارة (Loss Function).

Stochastic Gradient Descent




Gradient Descent




4 الانحدار المتدرج مع الزخم – Momentum Gradient Descent

- Mini-Batch Gradient Descent يتم تحديث النموذج باستخدام جزء صغير من البيانات في كل مرة.
- لذلك قد يختلف اتجاه ال Gradient من دفعة إلى أخرى.
- هذا الاختلاف قد يسبب تذبذبًا (Oscillation) في مسار التعلم.
- Momentum يستخدم التدرجات السابقة مع التدرج الحالي.
- يساعد ذلك على جعل التحديثات أكثر سلاسة وأقل تذبذبًا.
- يمكن تخيله مثل كرة تتدحرج إلى أسفل تل.
- كلما استمرت الكرة في نفس الاتجاه، تكتسب سرعة وزخمًا أكبر.




4 الانحدار المتدرج مع الزخم – Momentum Gradient Descent

SGD without Momentum




SGD with Momentum




5 التدرّج التكيفي – AdaGrad

- هي خوارزمية Gradient Descent العادية، جميع الأوزان تستخدم نفس Learning Rate.
- لكن بعض الأوزان قد تحتاج تحديثات أكبر، بينما أوزان أخرى تحتاج تحديثات أصغر.
- لذلك جاءت AdaGrad لتجعل الـ Learning Rate يتكيف بشكل مستقل مع كل وزن أثناء التدريب.




SGD



AdaGrad

5 التدرّج التكيفي – AdaGrad



الخطوة 1: نجمع مربعات التدرجات السابقة.


$$G_t = G_{t-1} + g_t^2$$

الخطوة 2: نحدّث الوزن باستخدام معدل تعلّم متكيّف.

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{G_t} + \epsilon} g_t$$

كلما زادت قيمة G_t ، يصغر مقدار التحديث لذلك الوزن؛ وكلما كانت G_t أصغر، يكون التحديث أكبر.

6 الجذر التربيعي لمتوسط مربعات التدرجات – RMSProp



- خوارزمية تحسين تكيفية (Adaptive Optimization Algorithm) تضبط حجم التحديث لكل معامل بشكل مستقل.
- تعتمد على المتوسط الأسّي المتحرك لمربعات التدرجات لتقدير حجم التدرجات الحديثة.
- صُممت لمعالجة مشكلة الانخفاض المستمر في معدل التعلم التي قد تظهر في AdaGrad.

6 الجذر التربيعي لمتوسط مربعات التدرجات – RMSProp

- تحسب متوسطًا أُسِّيًّا لمربعات التدرجات:

$$S_t = \beta S_{t-1} + (1 - \beta)g_t^2$$

- تحسب متوسطًا أُسِّيًّا لمربعات التدرجات:

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{S_t} + \epsilon} g_t$$

يمثل g_t التدرج الحالي، ويمثل S_{t-1} المتوسط السابق لمربعات التدرجات، بينما تحدد β مقدار الاعتماد على القيم السابقة، وينتج عن ذلك S_t بوصفه المتوسط الأسي المتحرك لمربعات التدرجات.

7 التقدير التكيفي للعزم – Adam

- خوارزمية تحسين تكيفية تجمع بين فكري Momentum و RMSProp لتحديث أوزان النموذج بكفاءة واستقرار
- Momentum يقلل التذبذب باستخدام متوسط التدرجات السابقة.
- RMSProp يكيّف معدل التعلم باستخدام متوسط مربعات التدرجات.
- Adam يجمع الطريقتين معًا للاستفادة من اتجاه التدرج وحجمه في الوقت نفسه.




7 التقدير التكيفي للعزم – Adam


- الخطوة 1: حساب متوسط التدرجات Momentum
$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$
- الخطوة 2: حساب متوسط مربعات التدرجات RMSProp
$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$
- الخطوة 3: تحديث الأوزان

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{v_t} + \epsilon} m_t$$


التقدير التكيفي للعزم – Adam

Adam Optimization Trajectory for Beale Function





تدريب الشبكة العصبية




- دالة التكلفة هي دالة هدف تقيّم أداء النموذج من خلال حساب إجمالي الخطأ على بيانات التدريب.

$$L(f(x^{(i)}), y^{(i)}) \sum_{i=1}^m \frac{1}{m} = J(w, b)$$

- نحدّث هذه المعاملات خطوة بخطوة، مع تقليل الخطأ تدريجيًا.
- تُسمى هذه العملية الانحدار المتدرج (Gradient Descent).

- يبدأ النموذج بقيم عشوائية للمعاملات (w, b)
- يحسب تدرّج دالة التكلفة (Gradient)



$$w = w - \alpha \frac{\partial}{\partial w} J(w, b)$$

$$b = b - \alpha \frac{\partial}{\partial b} J(w, b)$$

- إذا أدى تغيير w بمقدار صغير ϵ إلى زيادة دالة التكلفة $J(w)$ بمقدار $k \times \epsilon$ ، فإن المشتقة تكون:

$$K = \frac{d}{dw} J(w)$$

function $J(w) = w^2$

variable $w = 3$:

function $J(w) = 9$

lets increase w by $\epsilon=0.001$

$$w=3.001$$

$$J(w)=9.006001$$

دالة التكلفة (Cost Function)

$$6 \times 0.001 = 0.006$$

$$\frac{d}{dw} J(w) = 2w = 6$$

function $J(w) = w^2$

variable $w = 3$:


function $J(w) = 9$

lets increase w by $\epsilon=0.001$:

$$w=3.001$$


$$J(w)=9.006001$$

$$\Delta J \approx 0.006001$$



دالة التكلفة (Cost Function)

1- مشتقة دالة الخسارة بالنسبة للتنبؤ




$$\frac{\partial J}{\partial \hat{y}} = -\frac{y}{\hat{y}} + \frac{1 - y}{1 - \hat{y}}$$

$$\frac{\partial J}{\partial \hat{y}} = -\frac{0}{0.907} + \frac{1}{1 - 0.907} = \frac{1}{0.093} \approx 10.75$$

إذا تغيّر التنبؤ قليلاً، فسيتغيّر الخطأ بمقدار يقارب 10.75 ضعف هذا التغيّر.

دالة التكلفة (Cost Function)

2 - مشتقة دالة Sigmoid



$$\hat{y} = \sigma(z^{(2)}) = \frac{1}{1 + e^{-z^{(2)}}}$$

$$\frac{\partial \hat{y}}{\partial z^{(2)}} = \hat{y}(1 - \hat{y})$$

$$\frac{\partial \hat{y}}{\partial z^{(2)}} = 0.907(1 - 0.907) \approx 0.08435$$

دالة التكلفة (Cost Function)


3 - مشتقة دالة الخسارة بالنسبة إلى z^2 w.r.t
(قاعدة السلسلة):

$$\frac{\partial J}{\partial z^{(2)}} = \frac{\partial J}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z^{(2)}}$$

$$\frac{\partial J}{\partial z^{(2)}} \approx 10.75 \times 0.08435 \approx 0.907$$

sigmoid + binary cross-entropy


$$\frac{\partial J}{\partial z^{(2)}} = \hat{y} - y$$



$$\frac{\partial J}{\partial z^{(2)}} = \frac{\partial J}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z^{(2)}}$$

دالة التكلفة (Cost Function)

4- تدرجات طبقة الإخراج (Gradients of Output)
(Layer




$$z^{(2)} = W^{(2)}h + b^{(2)} = w_1^{(2)}h_1 + w_2^{(2)}h_2 + w_3^{(2)}h_3 + b^{(2)}$$

$$\frac{\partial z^{(2)}}{\partial w_j^{(2)}} = h_j, \quad \frac{\partial z^{(2)}}{\partial b^{(2)}} = 1$$

$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} = (\hat{y} - y) h_j$$

$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} = (\hat{y} - y) h_j$$

دالة التكلفة (Cost Function)

5 - التدرجات بالنسبة إلى التنشيطات المخفية h 


$$z^{(2)} = w_1^{(2)} h_1 + w_2^{(2)} h_2 + w_3^{(2)} h_3 + b^{(2)}$$

$$\frac{\partial z^{(2)}}{\partial h_j} = w_j^{(2)}$$

$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} =$$

$$\frac{\partial J}{\partial h_j} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial h_j} = (\hat{y} - y) w_j^{(2)}$$

دالة التكلفة (Cost Function)


5 - التدرجات بالنسبة إلى التنشيطات المخفية h Using $\hat{y} - y = 0.907$ and $W^{(2)} = [0.7, 0.5, 0.9]$:

- $\frac{\partial J}{\partial h_1} \approx 0.907 \times 0.7 = 0.635$
- $\frac{\partial J}{\partial h_2} \approx 0.907 \times 0.5 = 0.454$
- $\frac{\partial J}{\partial h_3} \approx 0.907 \times 0.9 = 0.816$

$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} :$$

دالة التكلفة (Cost Function)

٦- مشتقة دالة Sigmoid في الطبقة المخفية



$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} :$$


$$h_j = \sigma(z_j^{(1)}) \Rightarrow \frac{\partial h_j}{\partial z_j^{(1)}} = h_j(1 - h_j)$$

- $\frac{\partial J}{\partial z_1^{(1)}} \approx 0.635 \times 0.0099 = 0.00629$
- $\frac{\partial J}{\partial z_2^{(1)}} \approx 0.454 \times 0.01088 = 0.00493$
- $\frac{\partial J}{\partial z_3^{(1)}} \approx 0.816 \times 0.00299 = 0.00244$

دالة التكلفة (Cost Function)

٧- التدرجات بالنسبة لأوزان الطبقة المخفية

$$0.00244 = \frac{J \partial}{\frac{(1)}{3} z \partial}, 0.00493 = \frac{J \partial}{\frac{(1)}{2} z \partial}, 0.00629 = \frac{J \partial}{\frac{(1)}{1} z \partial}$$



$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} :$$


$$\begin{bmatrix} 3 \\ 5 \\ 2 \\ 4 \end{bmatrix}$$

$$i x \cdot \frac{J \partial}{\frac{(1)}{j} z \partial} = \frac{J \partial}{\frac{(1)}{ij} w \partial}$$

$$\frac{J \partial}{\frac{(1)}{j} z \partial} = \frac{J \partial}{\frac{(1)}{j} b \partial}$$

دالة التكلفة (Cost Function)

٧- التدرجات بالنسبة لأوزان الطبقة المخفية



$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} :$$

$$\begin{bmatrix} 3 \\ 5 \\ 2 \\ 4 \end{bmatrix}$$

$$0.00244 = \frac{J \partial}{\frac{(1)}{3} z \partial}, 0.00493 = \frac{J \partial}{\frac{(1)}{2} z \partial}, 0.00629 = \frac{J \partial}{\frac{(1)}{1} z \partial}$$

$$0.01887 = 3 \times 0.00629 = \frac{J \partial}{\frac{(1)}{11} w \partial}$$

$$0.03145 = 5 \times 0.00629 = \frac{J \partial}{\frac{(1)}{21} w \partial}$$


$$0.01258 = 2 \times 0.00629 = \frac{J \partial}{\frac{(1)}{31} w \partial}$$

$$0.02516 = 4 \times 0.00629 = \frac{J \partial}{\frac{(1)}{41} w \partial}$$

$$0.00629 = \frac{J \partial}{\frac{(1)}{1} b \partial}$$

دالة التكلفة (Cost Function)

٧- التدرجات بالنسبة لأوزان الطبقة المخفية



$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} :$$

$$0.00244 = \frac{J \partial}{\frac{(1)}{3} z \partial}, 0.00493 = \frac{J \partial}{\frac{(1)}{2} z \partial}, 0.00629 = \frac{J \partial}{\frac{(1)}{1} z \partial}$$

$$\begin{bmatrix} 3 \\ 5 \\ 2 \\ 4 \end{bmatrix}$$

$$0.01479 = 3 \times 0.00493 = \frac{J \partial}{\frac{(1)}{12} w \partial}$$

$$0.02465 = 5 \times 0.00493 = \frac{J \partial}{\frac{(1)}{22} w \partial}$$


$$0.00986 = 2 \times 0.00493 = \frac{J \partial}{\frac{(1)}{32} w \partial}$$

$$0.01972 = 4 \times 0.00493 = \frac{J \partial}{\frac{(1)}{42} w \partial}$$

$$0.00493 = \frac{J \partial}{\frac{(1)}{2} b \partial}$$

دالة التكلفة (Cost Function)

٧- التدرجات بالنسبة لأوزان الطبقة المخفية



$$\frac{\partial J}{\partial w_j^{(2)}} = \frac{\partial J}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial w_j^{(2)}} :$$

$$0.00244 = \frac{J \partial}{\frac{(1)}{3} z \partial}, 0.00493 = \frac{J \partial}{\frac{(1)}{2} z \partial}, 0.00629 = \frac{J \partial}{\frac{(1)}{1} z \partial}$$

$$\begin{bmatrix} 3 \\ 5 \\ 2 \\ 4 \end{bmatrix}$$

$$0.00732 = 3 \times 0.00244 = \frac{J \partial}{\frac{(1)}{13} w \partial}$$

$$0.01220 = 5 \times 0.00244 = \frac{J \partial}{\frac{(1)}{23} w \partial}$$


$$0.00488 = 2 \times 0.00244 = \frac{J \partial}{\frac{(1)}{33} w \partial}$$

$$0.00976 = 4 \times 0.00244 = \frac{J \partial}{\frac{(1)}{43} w \partial}$$

$$0.00244 = \frac{J \partial}{\frac{(1)}{3} b \partial}$$

دالة التكلفة (Cost Function)

قاعدة التحديث النهائية (لجميع الأوزان)



$$w_{\text{new}} = w_{\text{old}} - \alpha \frac{\partial J}{\partial w}$$

$$0.50 = {}^{(2)}_1 w \quad 0.898 = \frac{J \partial}{{}^{(2)}_1 w \partial}$$

$$0.898 \times 0.1 - 0.50 = {}^{(2)}_{\text{new},1} w$$

$$\boxed{0.4102} = 0.0898 - 0.50 =$$

قبل ما نمشي

ايش أهم قرار هندسي بتأخذه
بشكل مختلف بعد اليوم؟
